Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления» Дисциплина «Технологии машинного обучения»

Отчёт

по лабораторной работе №3

«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Вариант 3

Студент:

Белкина Е.В.

Группа ИУ5-61Б

Преподаватель:

Гапанюк Ю.Е.

Цель лабораторной работы:

Изучение способов предварительной обработки данных для дальнейшего формирования моделей.

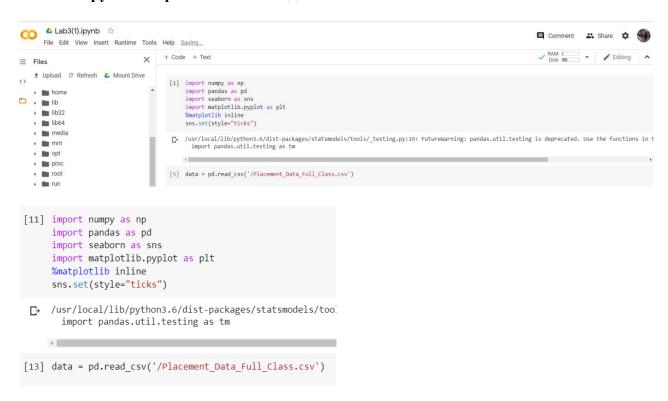
Задание:

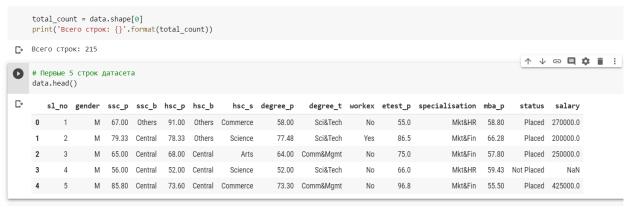
- Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - о обработку пропусков в данных;
 - о кодирование категориальных признаков;
 - о масштабирование данных.

Выполнение работы:

Выбранный датасет: https://www.kaggle.com/benroshan/factors-affecting-campus-placement

1. Загрузка и первичный анализ данных





[8]	# размер набора data.shape	данных	[3]	data.isnull().	sum()
C →	(215, 15) # типы колонок data.dtypes		C	sl_no gender ssc_p ssc_b hsc p	0 0 0 0
C+	sl_no gender ssc_p ssc_b hsc_p hsc_b hsc_s degree_p degree_t workex etest_p specialisation mba_p status salary dtype: object	int64 object float64 object float64 object object float64 object float64 object float64 object float64 object float64 object float64		hsc_b hsc_s degree_p degree_t workex etest_p specialisation mba_p status salary dtype: int64	0 0 0 0 0 0 0 0

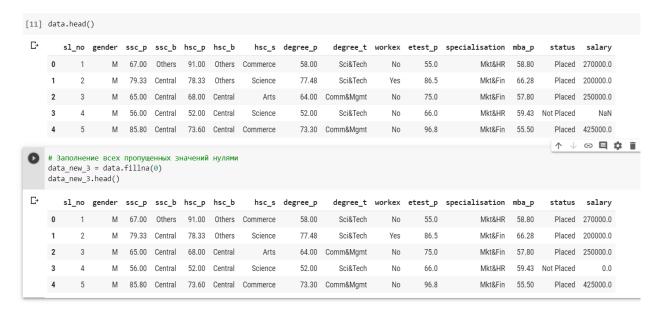
2. Обработка пропусков в данных

2.1. Простые стратегии - удаление или заполнение нулями

```
[9] # Удаление колонок, содержащих пустые значения data_new_1 = data.dropna(axis=1, how='any') (data.shape, data_new_1.shape)

☐→ ((215, 15), (215, 14))

[10] # Удаление строк, содержащих пустые значения data_new_2 = data.dropna(axis=0, how='any') (data.shape, data_new_2.shape)
```



2.2. "Внедрение значений" - импьютация (imputation)

```
[13] # Выберем числовые колонки с пропущенными значениями

# Цикл по колонкам датасета
num_cols = []
for col in data.columns:

# Количество пустых значений
temp_null_count = data[data[col].isnull()].shape[0]
dt = str(data[col].dtype)
if temp_null_count>0 and (dt=='float64' or dt=='int64'):
    num_cols.append(col)
    temp_perc = round((temp_null_count / total_count) * 100.0, 2)
    print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))

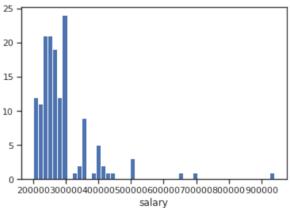
В Колонка salary. Тип данных float64. Количество пустых значений 67, 31.16%.

# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

```
₽
           salary
        270000.0
          200000.0
      1
          250000.0
      2
      3
              NaN
          425000.0
     210 400000.0
     211 275000.0
     212 295000.0
     213 204000.0
     214
    215 rows × 1 columns
```

Гистограмма по признакам
for col in data_num:
 plt.hist(data[col], 50)
 plt.xlabel(col)
 plt.show()

/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py
keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py
keep &= (tmp_a <= last_edge)</pre>

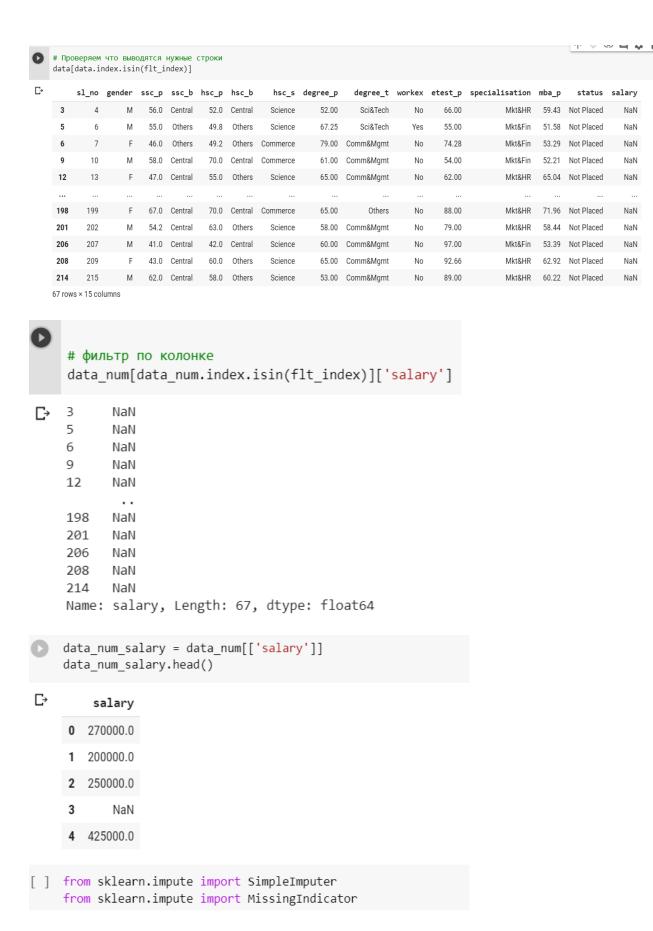


Фильтр по пустым значениям поля salary data[data['salary'].isnull()]

_}	s	1_no	gender	ssc_p	ssc_b	hsc_p	hsc_b	hsc_s	degree_p	degree_t	workex	etest_p	specialisation	mba_p	status	salary
	3	4	М	56.0	Central	52.0	Central	Science	52.00	Sci&Tech	No	66.00	Mkt&HR	59.43	Not Placed	NaN
	5	6	М	55.0	Others	49.8	Others	Science	67.25	Sci&Tech	Yes	55.00	Mkt&Fin	51.58	Not Placed	NaN
	6	7	F	46.0	Others	49.2	Others	Commerce	79.00	Comm&Mgmt	No	74.28	Mkt&Fin	53.29	Not Placed	NaN
	9	10	М	58.0	Central	70.0	Central	Commerce	61.00	Comm&Mgmt	No	54.00	Mkt&Fin	52.21	Not Placed	NaN
	12	13	F	47.0	Central	55.0	Others	Science	65.00	Comm&Mgmt	No	62.00	Mkt&HR	65.04	Not Placed	NaN
	198	199	F	67.0	Central	70.0	Central	Commerce	65.00	Others	No	88.00	Mkt&HR	71.96	Not Placed	NaN
	201	202	М	54.2	Central	63.0	Others	Science	58.00	Comm&Mgmt	No	79.00	Mkt&HR	58.44	Not Placed	NaN
	206	207	М	41.0	Central	42.0	Central	Science	60.00	Comm&Mgmt	No	97.00	Mkt&Fin	53.39	Not Placed	NaN
	208	209	F	43.0	Central	60.0	Others	Science	65.00	Comm&Mgmt	No	92.66	Mkt&HR	62.92	Not Placed	NaN
	214	215	М	62.0	Central	58.0	Others	Science	53.00	Comm&Mgmt	No	89.00	Mkt&HR	60.22	Not Placed	NaN
6	7 rows ×	< 15 col	umns													

Запоминаем индексы строк с пустыми значениями flt_index = data[data['salary'].isnull()].index flt_index

```
Int64Index([ 3,
                  5,
                       6,
                            9,
                               12,
                                    14,
                                         17, 18,
                                                   25,
                                                       29,
                               49, 51, 52, 63, 65, 68, 75, 79,
            41, 42,
                     45, 46,
            87, 91, 93, 97, 99, 100, 105, 106, 109, 111, 120, 130, 136,
           141, 144, 149, 155, 158, 159, 161, 165, 167, 168, 169, 170, 173,
           175, 179, 181, 182, 184, 186, 188, 189, 190, 194, 198, 201, 206,
           208, 214],
          dtype='int64')
```



```
# Фильтр для проверки заполнения пустых значений
   indicator = MissingIndicator()
   mask missing values only = indicator.fit transform(data num salary)
   mask_missing_values_only
□→ array([[False],
          [False],
          [False],
          [ True],
          [False],
          [ True],
          [ True],
          [False],
          [False],
          [ True],
          [False],
          [False],
          [True],
          [False],
          [ Truel.
          [False],
          [False],
          [ True],
          [ True],
          [False],
          [False],
          [False],
          [False],
          [False],
          [False],
          [ True],
          [False],
          [False],
          [False]
[31] strategies=['mean', 'median', 'most_frequent']
[32] def test num impute(strategy param):
          imp num = SimpleImputer(strategy=strategy param)
          data num imp = imp num.fit transform(data num salary)
          return data_num_imp[mask_missing_values_only]
      strategies[0], test_num_impute(strategies[0])
 [→ ('mean',
       array([288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541, 288655.40540541,
              288655.40540541, 288655.40540541, 288655.40540541]))
```

```
strategies[1], test_num_impute(strategies[1])
    ('median',
     array([265000., 265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000., 265000., 265000.,
            265000., 265000., 265000., 265000.]))
     strategies[2], test_num_impute(strategies[2])
    ('most_frequent',
      array([300000., 300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000., 300000., 300000.,
             300000., 300000., 300000., 300000.]))
[36] # Более сложная функция, которая позволяет задавать колонку и вид импьютации
    def test_num_impute_col(dataset, column, strategy_param):
        temp_data = dataset[[column]]
        indicator = MissingIndicator()
        mask_missing_values_only = indicator.fit_transform(temp_data)
        imp num = SimpleImputer(strategy=strategy param)
        data_num_imp = imp_num.fit_transform(temp_data)
        filled_data = data_num_imp[mask_missing_values_only]
        return column, strategy param, filled data.size, filled data[0], filled data[filled data.size-1]
    data[['salary']].describe()
₽
               salary
            148.000000
     count
     mean
          288655.405405
      std
           93457.452420
          200000.000000
     min
     25%
          240000.000000
```

50%

75%

max

265000.000000

300000.000000

940000.000000

```
[39] test_num_impute_col(data, 'salary', strategies[0])

☐→ ('salary', 'mean', 67, 288655.4054054054, 288655.4054054054)

[41] test_num_impute_col(data, 'salary', strategies[1])

☐→ ('salary', 'median', 67, 2650000.0, 2650000.0)

☐→ test_num_impute_col(data, 'salary', strategies[2])

☐→ ('salary', 'most_frequent', 67, 3000000.0, 3000000.0)
```

3. Преобразование категориальных признаков в числовые

```
[54] cat_temp_data = data[['degree_t']]
    cat_temp_data.head()
```

```
# Импьютация наиболее частыми значениями imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent') data_imp2 = imp2.fit_transform(cat_temp_data) data_imp2
```

```
[56] cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
     cat_enc
 ₽
                   c1
              Sci&Tech
       0
       1
              Sci&Tech
           Comm&Mgmt
              Sci&Tech
       3
           Comm&Mgmt
          Comm&Mgmt
      210
              Sci&Tech
      211
      212 Comm&Mgmt
      213 Comm&Mgmt
      214 Comm&Mgmt
     215 rows × 1 columns
[57] from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

3.1. Кодирование категорий целочисленными значениями - label encoding

```
[57] from sklearn.preprocessing import LabelEncoder, OneHotEncoder
[58] le = LabelEncoder()
    cat_enc_le = le.fit_transform(cat_enc['c1'])

Cat_enc['c1'].unique()

cat_enc['c1'].unique()

array(['Sci&Tech', 'Comm&Mgmt', 'Others'], dtype=object)

[60] np.unique(cat_enc_le)

array([0, 1, 2])

le.inverse_transform([0, 1, 2])

array(['Comm&Mgmt', 'Others', 'Sci&Tech'], dtype=object)
```

3.2. Кодирование категорий наборами бинарных значений - one-hot encoding

```
[63] ohe = OneHotEncoder()
     cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
[64] cat_enc.shape
 [→ (215, 1)
[65] cat_enc_ohe.shape
 [66] cat_enc_ohe
 C> <215x3 sparse matrix of type '<class 'numpy.float64'>'
            with 215 stored elements in Compressed Sparse Row format>
[67] cat_enc_ohe.todense()[0:10]
 matrix([[0., 0., 1.],
              [0., 0., 1.],
              [1., 0., 0.],
              [0., 0., 1.],
              [1., 0., 0.],
              [0., 0., 1.],
              [1., 0., 0.],
              [0., 0., 1.],
              [1., 0., 0.],
              [1., 0., 0.]])
      cat_enc.head(10)
 ₽
                  с1
       0
             Sci&Tech
             Sci&Tech
       2 Comm&Mgmt
       3
             Sci&Tech
         Comm&Mgmt
       5
             Sci&Tech
       6 Comm&Mgmt
       7
             Sci&Tech
         Comm&Mgmt
       9 Comm&Mgmt
```

3.3. Pandas get_dummies - быстрый вариант one-hot кодирования

<pre>[69] pd.get_dummies(cat_enc).head()</pre>
--

₽		c1_Comm&Mgmt	c1_Others	c1_Sci&Tech
	0	0	0	1
	1	0	0	1
	2	1	0	0
	3	0	0	1
	4	1	0	0

0

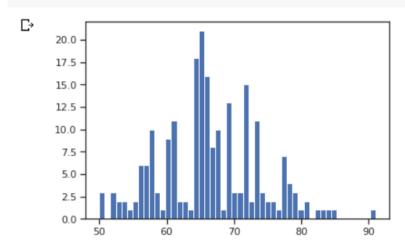
₽		degree_t_Comm&Mgmt	degree_t_Others	degree_t_Sci&Tech	degree_t_nan
	0	0	0	1	0
	1	0	0	1	0
	2	1	0	0	0
	3	0	0	1	0
	4	1	0	0	0

4. Масштабирование данных

[71] from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer

4.1. МіпМах масштабирование

```
[72] sc1 = MinMaxScaler()
    sc1_data = sc1.fit_transform(data[['degree_p']])
```



plt.hist(sc1_data, 50) plt.show() C> 20.0 - 17.5 - 15.0 - 12.5 - 10.0 - 7.5 - 5.0 - 2.5 - 0.0 0.2 0.4 0.6 0.8 1.0

4.2. Масштабирование данных на основе Z-оценки – StandardScaler

4.3. Нормализация данных

```
sc3 = Normalizer()
sc3_data = sc3.fit_transform(data[['degree_p']])

plt.hist(sc3_data, 50)
plt.show()
```

